Universidad Francisco Marroquín
Machine Learning for Business
Christian Medina
Javier Mazariegos

Utilidad Bruta en FoodMart

Luis Pedro González
Sebastian Mollinedo
25 / 10 / 2026

Índice

Introducción 3
Problema de negocio 3
Datos 3
Métodos 4
Selección del modelo 4
Resultados 5
Interpretación de negocio 6
Recomendaciones 6
Limitaciones 7
Conclusión 8

Introducción

FoodMart es una cadena ficticia de supermercados que opera tiendas en varios estados de Australia. Su dirección debe decidir constantemente dónde abrir nuevas sucursales y cómo operar las que ya existen, y cada decisión implica inversiones grandes que se recuperan con los años. Por eso, saber qué hace exitosa a una tienda es una necesidad real del negocio.

Este reporte documenta un proyecto de Machine Learning cuyo objetivo principal no es predecir con exactitud, sino apoyar una decisión estratégica. A partir de datos de 150 tiendas se identificaron las variables que más influyen en la utilidad bruta, se interpretó su efecto y se formularon recomendaciones para aumentar la probabilidad de éxito de los locales. Se siguió la metodología CRISP-DM y la solución se implementó en Kedro, de modo que pueda repetirse con un solo comando.

Problema de negocio

El stakeholder es la Dirección de Operaciones y Expansión de FoodMart, que decide dónde abrir tiendas y cómo manejarlas. Abrir una tienda en una ubicación equivocada es una pérdida difícil de corregir, y gastar en palancas que no funcionan también tiene un costo.

La pregunta de negocio es la siguiente. ¿Qué factores determinan la utilidad bruta de una tienda y qué debe hacer la empresa para aumentar la probabilidad de que una tienda sea exitosa? Se planteó como una regresión que predice la utilidad en millones de dólares, usada sobre todo para medir el efecto de cada variable.

El éxito se midió de dos formas. Técnicamente, con el error absoluto medio, la raíz del error cuadrático medio y el R^2, exigiendo superar una línea base que predice el promedio. Desde el negocio, será útil si deja claro qué variables mueven la utilidad y cuáles no. Una tienda exitosa se definió como parte del cuarto superior de utilidad, es decir las 38 tiendas que más ganan.

Datos

Los datos provienen de Kaggle, del conjunto FoodMart Dataset de dermisfit, y corresponden a 150 tiendas durante 2014, con 26 columnas por tienda. Incluyen la ubicación, la antigüedad, el personal, la publicidad, el número de competidores, el horario, la apertura en domingo, el estacionamiento, la canasta de compra y características del gerente. La utilidad bruta promedio es de 1.01 millones de dólares por tienda, con valores entre 0.02 y 2.87 millones.

Se revisaron valores faltantes, duplicados y atípicos. No se encontraron faltantes ni duplicados, y los atípicos se limitaron a un rango razonable. Se excluyeron las ventas y los salarios, porque son resultados de la operación y no decisiones previas a abrir una tienda. También se detectó que el número de competidores y las horas de atención tienen una correlación de 0.97, es decir que miden casi lo mismo, por lo que las horas se dejaron fuera del análisis de efectos para no mezclar ambos.

Métodos

El proyecto siguió las fases de CRISP-DM. En la limpieza se estandarizaron los nombres, se eliminaron las versiones en texto de las variables categóricas, se quitaron filas duplicadas o sin utilidad, y los valores atípicos se limitaron mediante el rango intercuartílico en lugar de borrar tiendas. Se creó una variable de crecimiento de la canasta entre 2013 y 2014, y los datos se dividieron en 120 tiendas para entrenar y 30 para probar.

Se entrenaron cuatro modelos. La línea base predice siempre el promedio. Un Ridge, que es una regresión lineal con una penalización que evita coeficientes exagerados, usa todas las variables. Un Random Forest, que combina muchos árboles de decisión, se ajustó con 12 combinaciones de hiperparámetros. Y un Ridge compacto usa solo las variables elegidas por una selección hacia adelante, que agrega una variable a la vez mientras mejore la predicción. Como 30 tiendas de prueba dan resultados muy variables, también se usó validación cruzada repetida 10 veces sobre las 150 tiendas.

Para el análisis de negocio se estimó el efecto de cada variable con una regresión múltiple, calculando su margen de error con la técnica bootstrap, y se comparó a las tiendas exitosas con el resto. Todo se organizó en Kedro con cuatro pipelines, de limpieza, entrenamiento, evaluación y análisis de negocio, con catálogo de datos y archivo de parámetros. En GitHub, un flujo de GitHub Actions revisa el código con Ruff, ejecuta las pruebas y verifica que el pipeline corra completo.

Selección del modelo

La Tabla 1 compara los cuatro modelos. El hallazgo más importante es que usar todas las variables no mejora la predicción, la empeora, porque la mayoría solo aporta ruido. El Ridge compacto, que quedó con el número de competidores y la apertura en domingo, fue el mejor en validación cruzada, con un R^2 de 0.475 y un error promedio de 0.322 millones, cerca de 38 por ciento menos que la línea base.

Tabla 1. Desempeño de los modelos.

Modelo	R^2 en validación cruzada	Error medio, millones	R^2 en prueba
Línea base, promedio	-0.042	0.520	-0.002
Ridge con todas las variables	0.355	0.385	0.336
Ridge compacto	0.475	0.322	0.210
Random Forest	0.412	0.353	0.212

En las 30 tiendas de prueba el Ridge con todas las variables quedó por encima, pero con una muestra tan pequeña esa diferencia cae dentro del ruido, ya que el R^2 varía unos 0.15 entre particiones. Por eso se prefirió la evaluación repetida sobre las 150 tiendas. El modelo final no

se eligió solo por la métrica, sino también porque es el más simple de explicar, y porque su mensaje es claro para la dirección, la decisión depende sobre todo de la competencia.

Resultados

La Figura 1 muestra el resultado central. A medida que aumenta el número de competidores cerca, la utilidad promedio cae de 1.66 millones sin competidores a apenas 0.2 millones con cinco o más, y la probabilidad de ser una tienda exitosa baja de 68 por ciento a cero. Entre las 23 tiendas con cinco o más competidores, ninguna llegó al cuarto superior de utilidad.

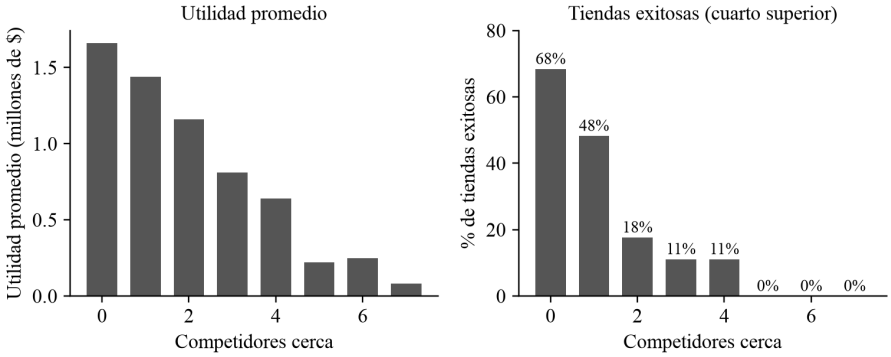


Figura 1. Utilidad promedio y porcentaje de tiendas exitosas según los competidores cerca. Elaboración propia.

La Figura 2 compara todas las variables. Muestra cuánto cambia la utilidad cuando cada una sube una cantidad típica, con su margen de error. Si la línea cruza el cero, el efecto no se distingue de la casualidad. La competencia destaca con gran diferencia, con un efecto cercano a 280 mil dólares menos por cada competidor adicional, con un intervalo de 220 a 340 mil. Las demás variables tienen efectos mucho menores o no distinguibles de cero.

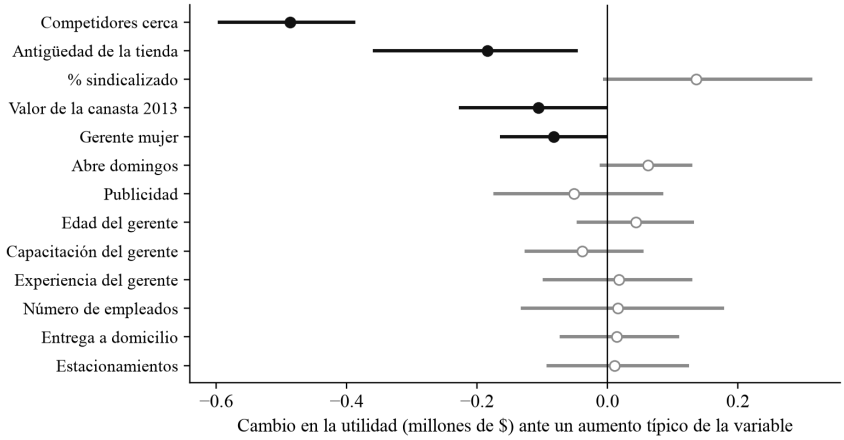


Figura 2. Efecto de cada variable sobre la utilidad, con intervalo de confianza de 95 por ciento. Elaboración propia.

Interpretación de negocio

Competencia. Es la variable que decide. Cada competidor adicional se asocia con unos 280 mil dólares menos, lo que equivale a más de una cuarta parte de la utilidad promedio. Con cero competidores, 68 por ciento de las tiendas es exitosa, con uno 48 por ciento, con dos 18 por ciento y con cinco o más ninguna.

Horario. Las tiendas con más competencia abren más horas, unas 12 más por cada competidor adicional. Por eso las horas se ven tan relacionadas con una menor utilidad, pero no se pueden separar de la competencia. Lo que sí indica es que ampliar el horario no es la solución, pues las tiendas más expuestas son las que más horas abren y las que menos ganan.

Publicidad y otras palancas. Por cada mil dólares adicionales en publicidad, la utilidad cambia entre menos 2.7 mil y más 1.3 mil dólares, un intervalo que incluye el cero, así que no hay evidencia de que gastar más funcione. Lo mismo ocurre con el número de empleados, el estacionamiento, la entrega a domicilio, la experiencia y capacitación del gerente y, en buena parte, con abrir los domingos. Como resume la Tabla 2, las tiendas exitosas se parecen al resto en todo menos en la competencia y el horario.

Tabla 2. Promedios de las 38 tiendas exitosas y del resto.

Variable	Tiendas exitosas	Resto de tiendas
Competidores cerca	1.1	3.0
Horas de atención	88	113
Antigüedad en años	9.0	8.8
Publicidad en miles de dólares	148	147
Empleados	60	62
Estacionamientos	43	45

Antigüedad. Cada año adicional se asocia con unos 34 mil dólares menos de utilidad, con un intervalo de 9 a 66 mil, por lo que conviene revisar si las tiendas más antiguas necesitan renovación.

Recomendaciones

La Tabla 3 traduce los hallazgos en una guía simple para evaluar ubicaciones. No es una regla rígida, porque la utilidad depende de otros factores, pero ordena las opciones según su probabilidad de éxito.

Tabla 3. Guía de decisión según los competidores cerca de la ubicación.

Competidores cerca	Utilidad promedio, millones	Probabilidad de ser exitosa	Decisión sugerida
0 a 1	1.4 a 1.7	48 a 68 por ciento	Abrir, prioridad alta
2	1.2	18 por ciento	Evaluar con cuidado
3 a 4	0.6 a 0.8	11 por ciento	Evitar salvo razones estratégicas
5 o más	0.2	0 por ciento	No abrir

Además de esa guía, se plantean las siguientes acciones.

- Usar la competencia cercana como criterio principal para abrir tiendas. Priorizar zonas con cero o un competidor, donde la probabilidad de éxito es de 48 a 68 por ciento, y ser exigentes con zonas de tres o más, donde baja a 11 por ciento o menos.
- No esperar que más publicidad o más horas rescaten una mala ubicación. Antes de aumentar ese gasto, probarlo en pocas tiendas y medir el resultado.
- Revisar el horario de las tiendas en zonas muy competidas. Son las que más horas abren y las que menos ganan, por lo que podría haber costos sin retorno.
- Revisar las tiendas más antiguas y decidir si requieren renovación, ya que su utilidad tiende a ser menor.
- Recolectar más información, como costos, tamaño de la zona, tráfico de clientes y más años de datos, para explicar la utilidad que hoy el modelo no explica.

Limitaciones

La muestra es pequeña, con 150 tiendas de un solo año y datos ficticios, por lo que los hallazgos no deben trasladarse directamente a una empresa real. El modelo explica cerca de la mitad de las diferencias de utilidad, así que el resto depende de factores no medidos. Los resultados muestran asociaciones y no causas. Que las tiendas con más competidores ganen menos no prueba que eliminar un competidor suba la utilidad, ya que otros factores pueden influir en ambos.

Al comparar muchas variables a la vez, alguna con efecto aparente, como la antigüedad, podría ser casualidad. La variable de gerente mujer muestra una utilidad menor, pero son solo 25 tiendas, el resultado es débil y podría reflejar a qué tiendas se asigna cada gerente. No debe usarse para decisiones de personal. Además, la validación cruzada del modelo compacto incluye tiendas usadas para elegir sus variables, por lo que su métrica puede ser algo optimista.

Conclusión

El proyecto permitió responder la pregunta de negocio de la Dirección de Operaciones y Expansión de FoodMart. De las 18 variables analizadas, una sola determina de forma clara la utilidad de una tienda, el número de competidores que tiene cerca. Un modelo basado en esa variable explica cerca de la mitad de las diferencias de utilidad entre tiendas y reduce los errores de predicción en alrededor de 38 por ciento frente a la línea base, lo cual es suficiente para comparar ubicaciones con un criterio objetivo. Esto responde directamente a lo que la empresa necesitaba saber, qué variables importan, cuánto pesan y en qué orden conviene actuar.

El efecto es grande y consistente. Cada competidor adicional se asocia con unos 280 mil dólares menos de utilidad, y la probabilidad de que una tienda sea exitosa baja de 68 por ciento sin competidores a cero con cinco o más. Para la empresa, esto significa que la decisión más importante al abrir una tienda es dónde se ubica, y que conviene priorizar zonas con pocos competidores antes que apostar por corregir una mala ubicación con otras acciones. Por ejemplo, dos ubicaciones similares con dos competidores de diferencia implican una utilidad esperada cercana a 0.56 millones menor para la peor ubicada, una brecha que difícilmente compensaría una campaña de publicidad.

Igual de valioso es lo que el análisis descartó. La publicidad, el número de empleados, el estacionamiento, la entrega a domicilio y las características del gerente no mostraron un efecto distinguible de la casualidad, y las horas de atención resultaron ser una consecuencia de la competencia y no una solución. Esto permite a la dirección dejar de asumir que más gasto o más horario se traducen en más utilidad, y reasignar recursos hacia probar y medir antes de invertir. En términos prácticos, el dinero que hoy se destina a ampliar horarios o a publicidad podría dirigirse primero a pilotos medibles y a estudiar mejor las ubicaciones antes de abrir.

En cuanto al modelo, el más simple fue también el mejor. Con solo 150 tiendas, agregar variables empeora la predicción, y un modelo lineal pequeño permite explicar a la dirección exactamente qué pesa y cuánto. Además es fácil de aplicar, porque basta conocer cuántos competidores hay cerca de una ubicación candidata para obtener una estimación. Aun así, debe usarse con prudencia, como apoyo para comparar opciones y no como un pronóstico exacto, ya que los datos son pocos, de un solo año y ficticios, y los resultados son asociaciones y no causas.

Como siguiente paso, el proyecto quedó organizado de forma reproducible en Kedro y validado automáticamente en GitHub, por lo que puede actualizarse con facilidad. Con más tiendas, más años de información y variables nuevas como los costos, el tamaño de la zona y el tráfico de clientes, la empresa podría mejorar la precisión del modelo y entender qué explica la mitad de la utilidad que todavía no se explica, para planificar su expansión con menos riesgo.