Universidad Francisco Marroquín
Machine Learning for Business
Christian Medina
Javier Mazariegos

Utilidad Bruta en FoodMart

Luis Pedro González
Sebastian Mollinedo
25 / 10 / 2026

Índice

Introducción 3
Problema de negocio 3
Datos 3
    Descripción del conjunto de datos 3
    Calidad de los datos y exploración 4
Métodos 4
Selección del modelo 5
Resultados 5
Interpretación de negocio 6
Recomendaciones 7
Limitaciones 7
Conclusión 8

Introducción

FoodMart es una cadena ficticia de supermercados que opera tiendas en varios estados de Australia. Su dirección debe decidir constantemente dónde abrir nuevas sucursales y cómo operar las que ya existen, y esas decisiones implican inversiones grandes que se recuperan con los años. Por eso, anticipar cuánto dinero dejará una tienda es una necesidad real del negocio y no solo un ejercicio académico.

Este reporte documenta un proyecto de Machine Learning que utiliza datos de 150 tiendas para estudiar qué factores se relacionan con su utilidad bruta y para construir un modelo que la estime. Se siguió la metodología CRISP-DM y la solución se implementó en Kedro, de modo que cualquier persona pueda repetirla con un solo comando. El texto busca ser comprensible para alguien que no sea especialista en ciencia de datos.

Problema de negocio

El stakeholder del proyecto es la Dirección de Operaciones y Expansión de FoodMart, que decide dónde abrir tiendas y cómo manejarlas una vez que funcionan. Abrir una tienda en una ubicación equivocada es una pérdida difícil de corregir, por lo que identificar a tiempo los factores que más pesan en la utilidad permite asignar mejor el dinero y el esfuerzo de la empresa.

La pregunta de negocio es la siguiente. ¿Qué factores operativos y de ubicación explican la utilidad bruta de una tienda, y es posible predecirla con una precisión útil para apoyar decisiones de expansión? Se planteó como un problema de regresión, en el que se predice la utilidad bruta de cada tienda, medida en millones de dólares.

El éxito técnico se midió con el error absoluto medio, la raíz del error cuadrático medio y el R^2, calculados sobre tiendas que el modelo no vio al entrenarse, exigiendo además que supere a una línea base que predice el promedio. Comercialmente, la solución será útil si identifica factores sobre los que la empresa pueda actuar. Si se adopta, la dirección podría comparar ubicaciones con un criterio objetivo y evitar abrir tiendas en zonas poco favorables.

Datos

Descripción del conjunto de datos

Los datos provienen de Kaggle y corresponden a 150 tiendas de FoodMart durante 2014, con 26 columnas por tienda. Incluyen la ubicación, que puede ser centro comercial, calle comercial o zona rural, el estado de Australia, la antigüedad, el personal, la publicidad, el número de competidores, el horario, la apertura en domingo, la entrega a domicilio, el estacionamiento, el porcentaje de empleados sindicalizados, el valor de la canasta de compra en 2013 y 2014 y características del gerente. La variable objetivo es la utilidad bruta, que en promedio fue de 1.01 millones de dólares por tienda, con valores entre 0.02 y 2.87 millones.

Calidad de los datos y exploración

Como los datos no están curados, se revisaron valores faltantes, duplicados y atípicos. No se encontraron faltantes ni duplicados, aunque el código está preparado para manejarlos. Se excluyeron las ventas y los salarios como variables predictoras, porque son resultados de la operación y no decisiones previas a abrir una tienda, y habrían hecho que el modelo pareciera mejor de lo que realmente es. En la exploración, el número de competidores mostró una correlación de menos 0.71 con la utilidad, mientras que la antigüedad y la publicidad casi no tuvieron relación lineal. La Figura 1 muestra que las tiendas sin competidores generan en promedio cerca de 1.66 millones, y las que tienen cinco o más apenas superan los 0.2 millones.

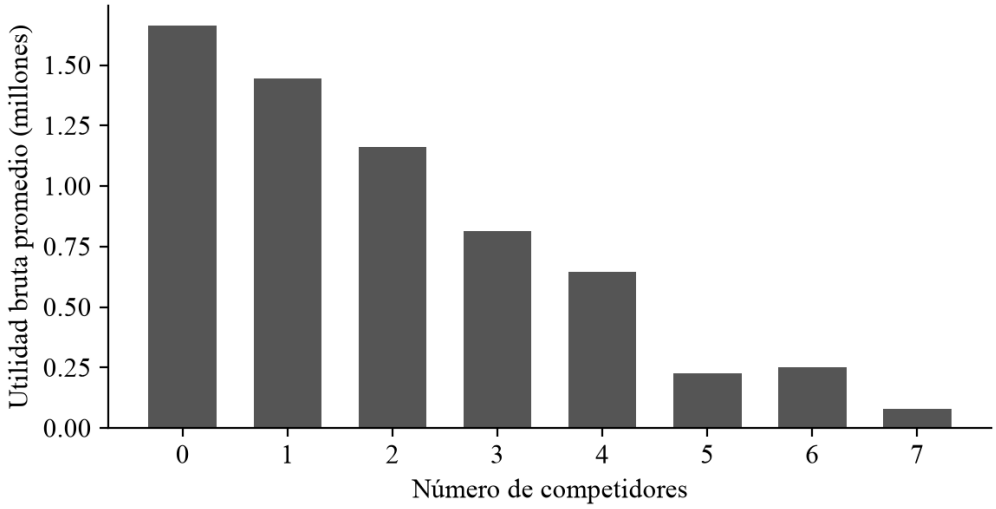


Figura 1. Utilidad bruta promedio según el número de competidores cercanos. Elaboración propia.

Métodos

El proyecto siguió las fases de CRISP-DM. Primero se definió la pregunta y la métrica, luego se exploró y limpió la base, después se entrenaron y compararon tres modelos, se evaluaron con datos de prueba y finalmente se dejó el proyecto organizado de forma reproducible.

En la limpieza se estandarizaron los nombres de las columnas, se eliminaron las versiones en texto de las variables categóricas porque ya existía su versión numérica, y se quitaron filas duplicadas o sin utilidad registrada. Los valores atípicos se limitaron a un máximo y un mínimo razonables mediante el rango intercuartílico, en lugar de borrar tiendas, para no perder observaciones en una base pequeña. La ubicación y el estado se trataron como categorías y las variables numéricas se estandarizaron. Además, se creó una variable nueva que mide el crecimiento porcentual de la canasta de compra entre 2013 y 2014.

Los datos se dividieron en 80 por ciento para entrenamiento, es decir 120 tiendas, y 20 por ciento para prueba, es decir 30 tiendas, con una semilla fija. La solución se organizó en Kedro

con tres pipelines, de limpieza, de entrenamiento y de evaluación, con nodos de responsabilidad clara, un catálogo de datos y un archivo de parámetros. En GitHub, un flujo de GitHub Actions instala las dependencias, revisa el código con Ruff, ejecuta las pruebas y verifica que el pipeline corra completo en cada cambio.

Selección del modelo

Se creó primero una línea base que predice siempre el promedio de utilidad, ya que un modelo que no la supere no aporta información. Luego se entrenaron una regresión Ridge, que es una regresión lineal con una penalización que evita coeficientes exagerados y funciona bien con pocos datos, y un Random Forest, que combina muchos árboles de decisión y puede captar relaciones más complejas. Para el Random Forest se probaron 12 combinaciones de hiperparámetros con validación cruzada de cinco particiones, y se eligió la de 300 árboles, profundidad de 3 y mínimo de 5 tiendas por hoja.

En el caso de Ridge se mantuvo el nivel de penalización estándar, ya que el modelo es simple y no mostró señales de sobreajuste con ese valor, y sus variables numéricas se estandarizaron para que todas estén en la misma escala y los coeficientes sean comparables entre sí. Este modelo, además, permite conocer el efecto de cada variable sobre la utilidad, algo que un conjunto de árboles no ofrece de forma directa.

El modelo final no se escogió solo por la métrica. También se consideró la interpretabilidad, porque la dirección necesita entender por qué una ubicación se espera rentable, y la facilidad de implementación, ya que un modelo lineal es simple de explicar, mantener y aplicar a una tienda nueva. Con estos criterios se seleccionó Ridge.

Resultados

La Tabla 1 resume el desempeño sobre las 30 tiendas de prueba. En los errores un valor menor es mejor, y en el R^2 uno mayor es mejor.

Tabla 1. Desempeño de los modelos en las tiendas de prueba.

Modelo	MAE	RMSE	R^2
Línea base, promedio	0.434	0.542	-0.002
Ridge	0.344	0.441	0.336
Random Forest	0.354	0.480	0.212

La línea base obtuvo un R^2 cercano a cero, como era de esperarse. Ridge fue el mejor modelo en las tres métricas, con un error absoluto de 0.344 millones y una raíz del error cuadrático de 0.441, lo que reduce los errores en cerca de 21 y 19 por ciento frente a la línea base. En términos del negocio, un error absoluto de 0.344 millones significa que, en promedio, la predicción se equivoca por unos 344 mil dólares, frente a una utilidad promedio de 1.01 millones. Su R^2 de 0.336 indica que explica alrededor de un tercio de las diferencias de utilidad

entre tiendas. El Random Forest superó a la línea base pero no a Ridge, lo que sugiere que con solo 150 tiendas un modelo más complejo no aprovecha su flexibilidad. La Figura 2 muestra las variables más importantes, donde el número de competidores destaca con gran diferencia.

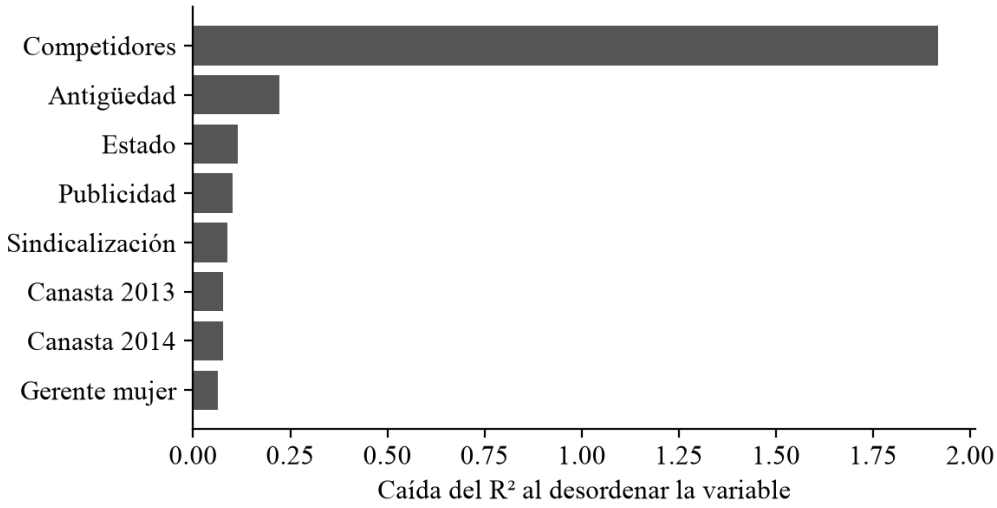


Figura 2. Importancia de las variables según el modelo Ridge. Elaboración propia.

Estos valores se calcularon con solo 30 tiendas, por lo que deben leerse como una referencia y no como una cifra exacta. Aun así, el patrón fue consistente en las tres métricas y coincide con lo observado en la exploración inicial, donde la competencia ya aparecía como el factor dominante. Esto da confianza en que el modelo capta una relación real y no un resultado fortuito de la partición de los datos.

Interpretación de negocio

La competencia es el factor que más se asocia con la utilidad. En el modelo Ridge, cada competidor adicional cercano se asocia con una reducción aproximada de 0.34 millones de dólares en la utilidad bruta, manteniendo constantes los demás factores, lo que equivale a cerca de una tercera parte de la utilidad promedio de 1.01 millones. Después de la competencia, la antigüedad y el estado mostraron una influencia moderada, y las tiendas más antiguas tienden a ganar algo menos. En cambio, la publicidad, las horas de atención y la apertura en domingo tuvieron un peso pequeño.

Como ejemplo práctico, si dos ubicaciones candidatas son similares en tamaño y costo, pero una tiene dos competidores más cerca que la otra, el modelo anticipa una utilidad cercana a 0.7 millones menor para la primera, una diferencia que difícilmente compensaría un mayor gasto en publicidad o un horario más amplio.

El estado también influye. Las diferencias entre estados que no se explican por las demás variables podrían reflejar condiciones locales, como el tamaño del mercado, los costos o los hábitos de consumo, aunque con tan pocas tiendas en algunos estados esta lectura debe

tomarse con cautela. En la práctica, dos tiendas con características operativas parecidas pueden rendir distinto solo por dónde están, por lo que la ubicación debe analizarse con tanto cuidado como la operación.

Estos resultados muestran asociaciones y no causas. Que las tiendas con más competidores ganen menos no prueba que eliminar un competidor aumentaría la utilidad, ya que otros factores, como el tamaño de la zona, pueden afectar a ambos.

Recomendaciones

A partir de los resultados se plantean las siguientes recomendaciones para la Dirección de Operaciones y Expansión.

- Incluir la competencia como criterio central al evaluar nuevas ubicaciones. Al ser el factor de mayor peso, conviene priorizar zonas con pocos competidores cercanos y ser más exigentes con los proyectos en zonas saturadas.
- Usar el modelo como apoyo para comparar ubicaciones y no como pronóstico exacto. Su capacidad de explicación es moderada, por lo que debe combinarse con la experiencia del equipo.
- Probar con proyectos piloto antes de aumentar la publicidad o ampliar horarios. Su efecto fue pequeño en los datos, así que conviene comprobar su rentabilidad en pocas tiendas antes de aplicarlos en toda la cadena.
- Revisar las diferencias entre estados y el desempeño de las tiendas más antiguas, para entender si hay condiciones locales o necesidades de renovación. Además, recolectar más datos, como el tamaño de la zona y el tráfico de clientes.
- Repetir el análisis cada año con datos nuevos, ya que el proyecto se puede ejecutar de nuevo con un solo comando, para verificar que la relación con la competencia se mantiene en el tiempo.

Limitaciones

La muestra es pequeña, con 150 tiendas y solo 30 para evaluar, por lo que las métricas pueden variar con otra partición. Los datos cubren un único año y son ficticios, así que los hallazgos no deben trasladarse directamente a una empresa real. El R^2 de 0.336 indica que gran parte de la utilidad depende de factores que no están en la base.

En cuanto a sesgos y riesgos, estados como Territorio del Norte, con cuatro tiendas, tienen muy pocos datos, por lo que las conclusiones sobre esas regiones son poco confiables. Las variables sobre los gerentes, como el sexo, no deberían usarse para decisiones de personal, pues solo el 17 por ciento son mujeres y el modelo podría reflejar esa desproporción. El recorte de atípicos también puede ocultar tiendas excepcionalmente exitosas, y confiar demasiado en el modelo podría llevar a descartar ubicaciones que sí serían rentables.

Conclusión

El proyecto permitió responder la pregunta de negocio planteada por la Dirección de Operaciones y Expansión de FoodMart. A partir de los datos de 150 tiendas se comprobó que la utilidad bruta puede predecirse de forma moderada con las características disponibles, y que el modelo Ridge supera con claridad a la línea base, reduciendo los errores de predicción en cerca de un quinto y explicando alrededor de un tercio de las diferencias entre tiendas. Esto significa que la empresa ya cuenta con una referencia objetiva para comparar ubicaciones, algo que antes dependía casi por completo del criterio personal.

El hallazgo principal es que el número de competidores cercanos es, por mucho, el factor que más pesa en la utilidad de una tienda. Cada competidor adicional se asocia con una reducción de aproximadamente 0.34 millones de dólares, una cifra muy significativa frente a la utilidad promedio. Otros aspectos que suelen considerarse importantes, como la inversión en publicidad o las horas de atención, mostraron una influencia mucho menor, lo que invita a no asumir sin pruebas que más gasto o más horario se traduzcan en más utilidad. Para el negocio, esto implica que el análisis de la competencia debería ocupar el primer lugar en cualquier evaluación de una nueva ubicación.

La elección de Ridge como modelo final respondió a un balance entre desempeño, interpretabilidad y facilidad de uso. Aunque el Random Forest es un modelo más flexible, con una muestra tan pequeña no logró mejorar los resultados, y su complejidad dificultaría explicar las predicciones. Un modelo lineal permite a la dirección entender cuánto aporta cada factor y aplicarlo a una tienda nueva sin infraestructura especial, lo cual aumenta la probabilidad de que sea utilizado en las decisiones reales.

Sin embargo, el modelo debe usarse con prudencia. Sus resultados son asociaciones y no relaciones causales, la muestra es pequeña, los datos cubren un solo año y son ficticios, y una parte importante de la utilidad depende de factores que no se midieron. Por eso su mejor uso es como una herramienta de apoyo para comparar ubicaciones candidatas, siempre acompañada del criterio y la experiencia del equipo, y cuidando que las variables personales de los gerentes no influyan en decisiones de personal.

Como siguiente paso, el proyecto quedó organizado de forma reproducible en Kedro y validado automáticamente en GitHub, de manera que puede actualizarse con facilidad cuando se disponga de más tiendas, más años de información y variables adicionales como el tamaño de la zona de influencia o el tráfico de clientes. Con esa información, la empresa podría mejorar la precisión del modelo y convertirlo en una herramienta estable para planificar su expansión de manera más informada y con menos riesgo.